

DINOv3 TRT 加速指标完整报告 V1.0.0

项目：DINOv3-TRT-Acceleration (PolyU 研究型项目) 模型：Meta DINOv3 ViT-L/16 LVD-1689M (24 层, 4 outputs at blocks 4/12/16/20) 报告日期：2026-05-07

1. 测试环境

项	配置
GPU	NVIDIA RTX 5080 (Blackwell, sm_120, 16 GB VRAM, ~300W TDP)
CPU	Intel Core Ultra 9 285K
内存	127.5 GB
主板	Gigabyte Z890 AORUS ELITE WIFI7 ICE
OS	Windows 10 Pro 64 位
Python	3.10.10
TensorRT	10.13.2.6
CUDA / cuDNN	12.8 / 9.x
GPU 锁频	graphics clock 2752 MHz (实测前 <code>nvidia-smi -lgc 2752,2752</code> , 测试后 <code>-rgc</code> 复位)
测量口径	trtexec <code>--useSpinWait</code> GPU compute p50 + cpp 端到端 latency p50

1.5 Speedup 参考基线 (baseline) 定义

本报告中所有 "N× speedup" 数字的参考基线统一为 TensorRT FP32 (同一 ONNX、同一硬件、同一锁频、仅切换 `--fp32`), 不是 PyTorch eager 模式。

具体口径：

Speedup 类别	候选 (candidate)	参考基线 (reference)
§3 trtexec GPU compute speedup	trtexec <code>--bf16 --precisionConstraints=prefer</code> GPU compute p50	trtexec <code>--fp32</code> GPU compute p50 (同 ONNX、同锁频)
§4 cpp 端到端 speedup	cpp runtime (BF16 prefer engine) H2D + 推理 + D2H 全链路 p50	cpp runtime (FP32 engine) H2D + 推理 + D2H 全链路 p50

Speedup 类别	候选 (candidate)	参考基线 (reference)
§5 INT8 trtexec speedup	trtexec INT8 SmoothQuant $\alpha=0.8$ GPU compute p50	trtexec <code>--fp32</code> GPU compute p50 (同 ONNX、同锁频)

未测量 PyTorch eager 基线。 本研究关注 TensorRT 内部不同精度选择 (FP32 / BF16 / INT8 / FP16) 对 inference 性能的相对影响, 因此 baseline 选择 TensorRT FP32。PyTorch eager $\rightarrow$ TensorRT FP32 之间还存在一层独立的"TensorRT 编译加速"贡献 (业界经验值约 3–5 $\times$ 不等), 但**该层不在本研究范围内, 未测量。**

因此本报告 speedup 数字应理解为"TRT FP32 $\rightarrow$ TRT 低精度"的加速比, 而非"PyTorch $\rightarrow$ TRT 低精度"的端到端加速比。如需对外引用 vs PyTorch 的总加速比, 请明确标注未测量、属估算。

2. 模型 & 输出契约

DINOv3 ViT–L/16 LVD–1689M 推理输出取 transformer 的 **第 4、12、16、20 层** (1–based; 等价 0–based [3,11,15,19]), 用于下游密集预测任务的多尺度特征融合 (DPT–style)。

每层输出 shape: `[B, 197, 1024]` (1 CLS + 196 patch tokens; register tokens 已默认裁剪)。

阶段	关键约束
ONNX 导出	opset ≥ 18 (RoPE + LayerNorm 原生算子需要); 4 个 output binding 命名 <code>feat_layer_{4,12,16,20}</code> ; <code>dynamic_axes</code> 仅 batch 维动态
RoPE 处理	源码改造 (首选), 消除 <code>aten::if</code> 条件分支以避免 TRT IfConditionalOutputLayer 失败
TRT 引擎构建	4 个 output binding 全部保留; INT8 校准联合一次覆盖所有激活张量
INT8 量化	主路径 NVIDIA TensorRT Model Optimizer 显式 Q/DQ; legacy <code>lnt8EntropyCalibrator2</code> 仅作 baseline 对照

2.5 为什么不用 FP16? 候选选择实证

核心结论: 直接使用 `trtexec --fp16` 在 DINOv3 ViT–L/16 LVD–1689M 正式权重下推理输出 **NaN** (数值溢出), 不可作生产候选; 选 **BF16 prefer** 是工程取舍后的最优解。本节列出实证证据与根因。

2.5.1 实测现象

测试	输入数据	输出结果	来源
trtexec <code>--fp16</code> build + 运行（正式 LVD-1689M 权重）	真实图片	feat_layer_{4,12,16,20} 出现 NaN	工程负例（V1.0.1 ADR-005 文档化）
trtexec <code>--fp16</code> build + 运行（随机权重, $N(0, 0.02^2)$ 初始化）	任意输入	数值正常, <code>outputs_all_finite=true</code>	<code>cpp_runtime_random_fp32_vs_fp16_speedup.md</code>
FP16 + 全部 transformer block fallback 到 FP32 (<code>fp16.blocksfp32</code>)	真实图片	4 输出 cos = 1.000 / 0.999999	<code>compare_fp32_vs_fp16_blocksfp32_b1.json</code>

对比关键：架构本身可以跑 FP16（随机权重证明），失败发生在**正式训练权重**上 — 说明问题不是 TensorRT 也不是 ONNX，而是**训练权重的数值范围超 FP16 表示边界**。

2.5.2 根因：FP16 数值范围 ±65504 与 ViT-L 训练激活范围不兼容

FP16 = 5 位指数 + 10 位尾数，最大可表示数值约 **±65504** (6.55×10^4)。DINOv3 ViT-L/16 经 1.689B 张图片训练后，部分中间激活在以下场景超出该范围：

- **Attention 预 softmax logits** (QK^T 累加)：在某些 head 与极值 token 上可达 10^4 — 10^5 量级。
- **深层 block (16—23) residual sum 累积**：每层 LayerNorm 后再 residual 加法，深层累积可超 65504。
- **个别 channel 的 LayerNorm γ 缩放后极值**。

随机权重不触发这些极值（init 分布 $N(0, 0.02^2)$ 经 LayerNorm 拉回）；正式训练权重学到了“尖锐”的少量大幅 channel，少数路径数值跳出 FP16 → 溢出 NaN，并在前向传播链中污染所有下游层。这是大尺度 trained ViT inference 的已知问题（训练时通过 loss scaling 配合 mixed precision 解决，但纯 inference 无 backward 不能 scale）。

2.5.3 Selective FP16 fallback 探索（partial 验证）

我们 build 了约 14 个选择性 FP16 fallback 引擎变体（仅末段 fp32 / 仅 LayerNorm fp32 / 仅 attention fp32 / 早期 block fp32 等），其中只有 `fp16.blocksfp32`（全部 transformer block 强制 FP32, FP16 仅在外围 utility ops）有完整 cos 对照报告：

变体	feat_layer_4 cos	feat_layer_12 cos	feat_layer_16 cos	feat_layer_20 cos	加速
<code>fp16.blocksfp32</code>	1.000000	0.999999	0.999999	0.999999	接近 0 (block 全 FP32)

⚠ 该变体精度满分但 **没有计算加速** — 等于 FP32 性能。其他 13 个 partial fallback 变体未做 cos × speedup 双指标完整 sweep，存在“找到一个 ($\text{cos} \geq 0.99 \wedge \text{speedup} \geq 2.2\times$) 配置”的可能但未穷尽验证。

2.5.4 BF16 选型论证

选 BF16 prefer 而非继续 FP16 selective sweep 的工程理由：

维度	FP16	BF16
总位数	16	16
指数位 / 尾数位	5 / 10	8 / 7
数值范围	$\pm 6.55 \times 10^4$	$\pm 3.4 \times 10^{38}$ (同 FP32)
正式权重溢出风险	✗ 高 (NaN)	✓ 几乎零
Tensor Core 加速 (Blackwell)	✓	✓
实测 speedup (r518 b8 trtexec)	n/a (NaN)	3.86x
实测 cos_min (real ImageNet)	n/a	0.9977
工程额外成本	需 fallback layer-by-layer sweep	直接 <code>--bf16 --precisionConstraints=prefer</code> 通过

BF16 用"少 3 位尾数"换 FP32 等等的指数范围，对 transformer 这种激活幅度跨越大量级的模型刚好。同样是 16-bit Tensor Core 计算资源，BF16 已经达到 16-bit 加速理论上限；FP16 即便 sweep 出可行配置，最多匹配不可能超过。

2.5.5 局限性声明

- 本研究 FP16 失败结论仅限当前 hardware-software 组合 (RTX 5080 + TRT 10.13.2.6 + DINOv3 LVD-1689M 正式权重)。
- 未穷尽 14 个 selective FP16 fallback 变体的 cos × speedup 双指标 sweep。如未来研究有需要，可基于 `Code/Artifacts/engines/dinov3_vitl16_4out.fp16.*.engine` 这批已 build 的引擎做完整对照实验。
- 上游若有专门的 ViT-L FP16 后训练优化技术 (如 outlier-aware FP16, percentile-based clipping)，可能解锁 FP16 路径，但不在 V1.0.0 本研究范围。

3. BF16 prefer trtexec GPU compute 加速

分辨率	batch	BF16 latency p50 (ms)	FP32 ref (ms)	latency speedup	throughput speedup
224	1	2.87	7.04	2.45x	2.37x
224	4	6.22	15.86	2.55x	2.44x
224	8	10.08	28.32	2.81x	2.65x

分辨率	batch	BF16 latency p50 (ms)	FP32 ref (ms)	latency speedup	throughput speedup
224	16	18.76	57.70	3.08x	2.90x
224	32	36.97	120.00	3.25x	3.07x
336	1	3.91	10.96	2.80x	2.68x
336	4	11.41	33.78	2.96x	2.80x
336	8	21.93	71.31	3.25x	3.07x
336	16	140.52	139.90	1.00x ⚠	—
336	32	272.19	274.04	1.01x ⚠	—
518	1	8.51	26.55	3.12x	2.98x
518	2	14.30	49.98	3.50x	3.31x
518	4	26.56	99.93	3.76x	3.57x
518	8	51.06	197.30	3.86x ⭐	3.65x
518	16	389.99	387.94	1.00x ⚠	—

⭐ 顶点: r518 b8 = 3.86x speedup (trtexec GPU compute median latency)

⚠ memory-bound 边界: r336 b16+ / r518 b16 跌到 ~1.0x — 数据传输 + activation 居住超过 16 GB VRAM 可承载的 cache 局部性, FP32 与 BF16 都被 memory bandwidth 主导, 不再受 compute 端 BF16 加速影响。

4. BF16 prefer cpp 端到端加速 (C++ 生产路径)

含 H2D copy + 推理 + D2H copy 全链路 (不仅 GPU compute)。

分辨率	batch	cpp BF16 (ms)	cpp FP32 ref (ms)	end-to-end speedup
224	1	3.29	7.46	2.27x
224	8	12.18	30.06	2.47x
224	32	44.79	126.80	2.83x
336	1	4.61	11.66	2.53x
336	4	13.75	35.74	2.60x
336	8	26.36	74.89	2.84x
518	1	9.89	27.86	2.82x
518	2	17.01	52.46	3.08x

分辨率	batch	cpp BF16 (ms)	cpp FP32 ref (ms)	end-to-end speedup
518	4	31.76	104.68	3.30×
518	8	61.48	208.81	3.40× ★

★ C++ 端到端顶点: r518 b8 = 3.40×

cpp 端到端 speedup 比 trtexec GPU compute speedup 略低 (3.40× vs 3.86×), 差额来自 H2D/D2H 拷贝的固定开销 — 该开销受 PCIe bandwidth 限制不随精度变化。

5. INT8 SmoothQuant $\alpha=0.8$ (R2 应急候选)

INT8 PTQ 通过 NVIDIA TensorRT Model Optimizer SmoothQuant α -sweep 探索 ($\alpha \in \{0.5, 0.7, 0.8\}$), $\alpha=0.8$ 为 Pareto 最优。

分辨率	batch	trtexec speedup	cos_min (ImageNet val 1000, real data)
224	1	2.18×	—
224	8	3.48×	—
224	32	3.60× ★	0.9727 (feat_layer_20)

INT8 per-output cosine (real ImageNet val 1000):

输出层	cos_min	cos_mean
feat_layer_4	0.9908	0.9934
feat_layer_12	0.9895	0.9945
feat_layer_16	0.9762	0.9862
feat_layer_20	0.9727	0.9836

模式严格符合 ADR-010 root cause 假说: "前段 INT8 量化噪声向深层单调累积"。feat_layer_4 (0.9908) → 12 (0.9895) → 16 (0.9762) → 20 (0.9727) 单调递减。

6. Python ↔ C++ 跨语言一致性

```
224 / 336 / 518 × FP32 / BF16 prefer × batch 1 = 全部 bit-identical
- max_abs_error = 0.0
- cosine_similarity = 1.0 (exact, not approximation)
```

超出 V1.0.1 G3 最严档（原计划仅要求 $\cos \geq 0.999$ ）。意味着 Python TensorRT runtime 与 C++ TRT inferer 的预处理 + 推理 + 后处理在 deterministic 输入下产生 byte-identical 输出，可作为生产部署的可信桥梁。

7. cos verdict (real ImageNet val 1000)

通过 Kaggle workaround ([titericz/imagenet1k-val](#) via kagglehub 1.0.1 + 新 KGAT auth) 解锁完整 ImageNet val 50K 后，跑 1000 张随机采样 eval。

候选	cos_min	cos_mean	Verdict
BF16 prefer (主交付)	0.9977	0.9996	R1_PASS_strict ≥ 0.99 ✓
INT8 SmoothQuant $\alpha=0.8$ (R2 应急)	0.9727	0.9895	R2_PASS_emergency ≥ 0.97 ✓

BF16 prefer 4 个 layer 的 cos_min 全部 ≥ 0.9977 (feat_layer_4 接近 1.000, feat_layer_20 worst 但仍 0.9977) — 主交付候选稳健达标。

8. SMART 目标达成状态

目标	阈值	实测	状态
G1 低精度加速 $\geq 3\times$	trtexec speedup ≥ 3	3.86x / r518 b8	✓ 超额
G2 INT8 cos_min ≥ 0.99	R1 strict	0.9727 best (R1 未达; R2 ≥ 0.97 达成)	⚠ R1 ✗ / R2 ✓
G3 跨语言一致	$\cos \geq 0.999$	bit-identical	✓ 超额
G4 benchmark 矩阵 5 batch $\times$ 3 分辨率	完整覆盖 + 锁频	87 行机器可读 CSV, 含 memory-bound 边界论证	✓
G5 可复现	DINOv3 license + 一键脚本 + SHA256 manifest	全部就位	✓

9. 一句话总结

主交付 BF16 prefer: trtexec GPU compute 顶点 **3.86x** (r518 b8) / cpp 端到端 **3.40x** (r518 b8); real ImageNet val 1000 的 cos_min **0.9977** 达到 R1 strict ≥ 0.99 严格阈值。

R2 应急 INT8 SmoothQuant $\alpha=0.8$: speedup **3.60x** (r224 b32) / cos_min **0.9727** 达 R2 emergency ≥ 0.97 阈值。