

DINOv3 TRT V1.0.2 Delta 报告

DINOv3 TRT 加速指标 V1.0.2 Delta 报告

项目: DINOv3-TRT-Acceleration (PolyU 研究型项目) 版本: V1.0.2 delta on top of V1.0.0/V1.0.1 baseline 报告日期: 2026-05-02 数据来源: Code/Artifacts/reports/ (87 行 V1.0.1 matrix + V1.0.2 实验数据) + V1.0.0 ImageNet val 1000 cosine verdict

这是 V1.0.0 主报告 (TRT_acceleration_metrics_V1.0.0.pdf) 的增量章节, 文档化 V1.0.2 探索的实测结果与 precision-wall 系统性论证。V1.0.0 数字保持冻结。

1. V1.0.2 范围与目标

V1.0.2 旨在突破 V1.0.1 主交付候选 (BF16 prefer, 3.40x cpp r518 b8 + cos_min 0.9977) 的速度上限, 旗舰目标 **cpp end-to-end $\geq 5.0\times$ speedup at r518 b8 同时 cos_min ≥ 0.99 on real ImageNet val 1000**。

技术方向 (按 ADR-012/013/015/016/017/018 顺序):

ADR	技术	期望增益 (plan time)	实测增益	状态
012	CUDA Graphs + Pinned Memory	1.05–1.15x	r224 b1: 1.135x / r518 b8: 1.005x	Implemented–Partial
013	trtexec.py 扩展 (multi-profile + opt5 + persistent cache + sparsity flag)	1.05–1.10x	r518 b8: 1.000x (noise)	Implemented–Mixed
014	TRT 10.16.1 升级	5–10%	(blocked on user NVIDIA login)	Proposed
015	Multi-stream concurrent pool	aggregate $\geq 3.0\times$ at N=4	aggregate 1.513x at N=2 sweet spot	Implemented–Partial
016	2:4 structured sparsity	1.2–1.5x	all positions FAIL (precision wall)	Implemented–Negative
017	FP8 refined scaling	1.2–1.6x	catastrophic FAIL (cos 0.13)	Confirmed–Negative
018	Custom CUDA fused kernel	1.10–1.30x	(research-level, not started)	Proposed

2. ADR-012 · CUDA Graphs 实测 (Implemented)

C++ runtime 在 `enqueueV3` 路径插入 CUDA Graph capture/replay, 环境变量 `DINOV3_USE_CUDA_GRAPH=1` 控制 (fallback to V1.0.1 sequential path with `=0`)。

实测 on `dinov3_vitl16_4out.bf16.prefer.engine` + RTX 5080 + TRT 10.13.2.6:

Config	V1.0.1 legacy median	V1.0.2 Graph median	Speedup
r224 b1	3.33 ms	2.94 ms	1.135x 🌟
r518 b8 (旗舰点)	62.43 ms	62.13 ms	1.005x

跨语言 parity 验证: C++ Graph path vs Python TRT runtime, 4 layer outputs 全部 `max_abs_error=0` / `cosine_similarity=1.0` / **bit-exact** ✓。

结论: CUDA Graphs 在 low batch (launch overhead 占主导) 显著有效, r518 b8 (compute-dominated) 几乎无效。完全符合 launch-vs-compute 假说。

3. ADR-013 · trtexec.py 扩展 (Implemented–Mixed)

V1.0.2 加入 `--builder-optimization-level` / `--persistent-cache-size-mb` / `--enable-sparsity` / `--additional-profile` CLI flags 与 `TrtExecConfig` 字段。+12 单元测试 (pytest 357 → 369 passed)。

实测 acceptance gate failures:

- 1. `--persistentCacheSize` flag 在 TRT 10.13.2.6 不存在 (trtexec 报 `Unknown option`) — 该 flag 是 TRT 10.16+ 才加; 待 ADR-014 升级解锁。
- 2. `--builderOptimizationLevel=5` 在 r518 b8 BF16 prefer 上 negative:
 - V1.0.1 baseline (default level 3, 490 MB engine): median 62.02 ms
 - V1.0.2 build (level 5, 490.1 MB engine): median 62.03 ms
 - Speedup 1.0016x — 测量噪声内 (ADR-013 阈值 $\geq 1.05\times$)

Root cause: ViT-L/16 BF16 在 TRT 10.13.2.6 上 level 3 已接近最优 kernel, level 5 没有更好选择空间。

- 3. `--layerPrecisions=*:bf16` + `--precisionConstraints=prefer` 是关键组合 (V1.0.1 baseline 用此组合得 490 MB BF16 engine; 不传则 TRT 默认把多数层留 FP32 $\rightarrow$ 966 MB / 200 ms 3x regression) — 已在 V1.0.2 build 流程内文档化。

4. ADR-015 · Multi-Stream Concurrent Inference (Implemented-Partial)

ThreadPoolExecutor + threading.Barrier 跨 N worker concurrent inference。每 worker 独立 TRT engine + IExecutionContext + cudaStream + buffers。

实测 on r224 b1 BF16 prefer (50 warmup + 200 iter per worker):

N streams	aggregate qps	speedup vs N=1	p50 latency ms
1	343.69	1.000x	2.88
2	520.18	1.513x 	3.82
4	423.81	1.233x 	7.70

关键 finding: — N=2 是 sweet spot (aggregate 1.513x) — N=4 过度并发反而退化 (1.233x < 1.513x, per-worker p50 latency 7.70 ms = 2.7x N=1 baseline) — RTX 5080 84 SM 在 4 worker x ViT-L 单 inference 下饱和 — 单 inference 用 ~70% SM, 剩 30% 空隙给 N=2; N=4 在已饱和 SM 上排队

Acceptance gate 部分达成: —  G4 N=4 aggregate $\geq 3.0\times$ — Not Achieved (1.23x) —  N=2 aggregate $\geq 1.7\times$ — Marginal (1.513x, 差 0.19x)

5. ADR-016 · 2:4 Structured Sparsity 完整 Ablation (Implemented-Negative)

Forward-from-block-0 ablation (每加一块 sparsity) on real ImageNet val 1000:

k blocks	matmul mask 数	feat_layer_20 cos_min	OVERALL	Verdict
k=1 (block 0 only)	6/120	0.9909	0.9909	R1_PASS_strict
k=2 (blocks 0-1)	12/120	0.9693	0.9693	FAIL
k=4 (blocks 0-3)	24/120	0.9421	0.9421	FAIL
k=8 (blocks 0-7)	48/120	0.8724	0.8724	FAIL
k=12 (blocks 0-11)	72/120	0.8156	0.8156	FAIL
k=16 (blocks 0-15)	96/120	0.7053	0.7053	FAIL
k=20 (blocks 0-19) / full	120/120	0.5824	0.5824	FAIL

Reverse hypothesis — block 19 ONLY sparsity（最末块，误差无下游传播）：

Layer	cos_min	注解
feat_layer_4	0.9999	不受 block 19 影响（block 19 在下游）
feat_layer_12	0.9995	同上
feat_layer_16	0.9981	同上
feat_layer_20	0.9505	block 19 sparsity 直接输出 → FAIL R2

决定性结论： – 2:4 PTQ sparsity 没有 viable scaling subset – Block 0 唯一 R1 PASS（cos 0.9909）只因 23 层下游 LayerNorm 平滑了误差 – Block 19 单块同样 FAIL（无下游 smoothing） – 每多一块 sparsified，feat_layer_20 cos_min 单调下降

Root cause: 与 ADR-010 V1.0/V1.1/V1.2 mixed-precision 完全同模式 — 前段 weight pruning 误差通过 transformer block 累积放大，深层 catastrophic collapse。

ADR-016 接口实施完成（NumPy mask gen + ONNX rewriter，35 单元测试 PASSED），但 ship 路径仅限 block 0 single-block 作 demonstrative artifact（论文 example），不作主交付加速向量。

6. ADR-017 · FP8 Refined Scaling 实测（Confirmed-Negative）

V1.1 stretch 已生成的 `dinov3_vitl16_4out.fp8.modelopt.imagenette_calib500.engine` 对 FP32 reference 跑 cos eval on real ImageNet val 1000:

Layer	cos_min
feat_layer_4	0.3545
feat_layer_12	0.3047
feat_layer_16	0.1299
feat_layer_20	0.1798
OVERALL	0.1299 catastrophic FAIL

结论：FP8 PTQ 在 TRT 10.13.2.6 + Blackwell sm_120 + ViT-L/16 LVD-1689M 上 cos collapses 完全（output 接近随机）。Per-tensor + per-channel hybrid scaling refinement (ADR-017 §4) 无法救援这种规模的 collapse — 需 V1.3 QAT 或 TRT 11+ 成熟 Blackwell FP8 path。

7. PTQ Precision Wall — 5 vector 综合分析

V1.0.2 探索的 5 个 PTQ-style 向量在 real ImageNet val 1000 上的 cos_min:

量化技术	cos_min	Verdict	来源
BF16 prefer (V1.0.1 主交付)	0.9977	✅ R1_PASS_strict	V1.0.1 baseline
INT8 SmoothQuant α=0.8	0.9727	⚠️ R2_PASS_emergency	V1.0.1 R2 应急
2:4 sparsity k=1 (block 0)	0.9909	✅ R1_PASS_strict (仅 outlier)	V1.0.2 ADR-016
2:4 sparsity k=2+ (any extension)	≤ 0.9693	❌ FAIL	V1.0.2 ADR-016 ablation
2:4 sparsity full network	0.5824	❌ FAIL	V1.0.2 ADR-016
2:4 sparsity block 19 only	0.9505	❌ FAIL	V1.0.2 ADR-016 reverse test
FP8 ModelOpt PTQ	0.1299	❌ catastrophic	V1.1 stretch + V1.0.2 re-eval

Pattern：除 BF16 prefer 外，所有 PTQ-style 量化在 TRT 10.13.2.6 + ViT-L/16 LVD-1689M 上不可用。INT8 (R2 only) / sparsity (block 0 outlier only) / FP8 (catastrophic) 全部 hit 同一 precision wall。

Root cause (统一)：前段（前几个 transformer block）量化/pruning 引入的误差通过 21+ 个 attention + MLP block 累积放大；至 feat_layer_20 已偏离 FP32 baseline $10^{-1} \sim 10^0$ 量级，cosine 严重退化。

Implication：PTQ paradigm（不改权重，仅改 representation precision）已穷尽。**唯一突破路径是 QAT**（在量化 grid 上重新优化权重，让前段误差从 $\sim 10^{-2}$ 量级压到 $\sim 10^{-3}$ 量级）。

8. V1.0.2 Stacked Speedup Envelope（实证 + 估算）

V1.0.1 baseline cpp r518 b8: **3.40x** vs FP32 reference

V1.0.2 r518 b8 latency contributions（实测）：

增益向量	倍率	累计	备注
V1.0.1 BF16 prefer baseline	—	3.400x	start
+ ADR-012 CUDA Graphs (1.005x)	1.005	3.417x	r518 b8 compute-dominated
+ ADR-013 opt5 (1.000x, noise)	1.000	3.417x	TRT 10.13.2.6 already optimal
+ ADR-015 multi-stream (latency, 1.000x)	1.000	3.417x	throughput vector, not latency
+ ADR-016 selective sparsity block 0 (~1.010x)	1.010	3.451x	1/24 network only
V1.0.2 stacked envelope on TRT 10.13.2.6 + PTQ:		3.45x	
V1.0.2 旗舰目标:		5.00x	
Gap:		1.55x (45% additional)	

5.0x 不可达 without V1.3 QAT 或 TRT 11+ 上游变化。

可能突破组合（推测，未实施）： – ADR-014 TRT 10.16.1: ~5–10% (blocked on user NVIDIA login) – ADR-018 custom CUDA kernel: ~10–30% (research-level, 4 weeks, NaN risk) – 优化估算: $3.42 \times 1.07 \times 1.30 = 4.76x$ （仍不到 5.0x） – 保守估算: $3.42 \times 1.05 \times 1.10 = 3.95x$

9. V1.0.2 实际交付清单（What Was Delivered）

文档（Wiki/0-项目计划/）

- 项目计划报告_V1.0.2.md — V1.0.2 主计划
- ADR-012 ~ ADR-018（共 7 份 Proposed → 4 份 Implemented-X）

Code（Code/）

- cpp/include/dinov3_trt/pinned_buffer.h + cpp/src/pinned_buffer.cpp — RAll pinned host memory
- cpp/include/dinov3_trt/cuda_graph_pool.h + cpp/src/cuda_graph_pool.cpp — Graph capture/replay LRU cache
- cpp/src/trt_inferer.cpp — 集成 Graph + feature flag DINO_V3_USE_CUDA_GRAPH
- cpp/CMakeLists.txt — 新源码注册
- src/dinov3_trt/engine/trtexec.py — 多 profile + opt level + persistent cache + sparsity flag
- src/dinov3_trt/sparsity/__init__.py + sparsify.py — NumPy 2:4 mask 生成 lib
- scripts/sparsify_onnx_weights.py — ONNX weight rewriter driver
- scripts/build_engine_trtexec.py — V1.0.2 CLI flags 暴露
- scripts/benchmark_multi_stream.py — Python multi-stream throughput benchmark

测试 (Code/tests/)

- test_trtexec.py +12 V1.0.2 测 (全 BuildConfig/CLI flag 覆盖)
- test_sparsify.py 25 测 (mask 生成 + 边界情况)
- test_sparsify_onnx_weights_script.py 10 测 (ONNX driver mock 测试)
- 总计 +47 V1.0.2 测, pytest 357 → 404 passed, 3 skipped

Quality gate

- ruff + mypy --strict 全绿 (含 mypy --strict scripts/...)
- C++ build 8/8 OK + 1/1 contract test passed
- 跨语言 parity bit-exact 验证

V1.0.0 baseline 保护

- BF16 prefer cos_min on real ImageNet val 1000: 0.9977 (V1.0.0 数字未退化)
- 3 commits push 到 GitHub (cf5e721 → 6acb5bb → 5f2f185 → 7c9885a → dc974f7 → 9c51856 → f270fa4 → e24153f)

10. 推荐目标调整与下一步

现实化目标

指标	V1.0.2 旗舰 (unrealistic)	V1.0.2 实证可达	V1.0.2 推荐目标
cpp r518 b8 speedup	≥ 5.0x	3.45x	≥ 3.5x minimum / 4.0x stretch
cpp r224 b1 speedup	(含在 G1)	1.135x	≥ 1.10x (achieved)
Multi-stream N=2 aggregate	≥ 1.7x	1.513x	≥ 1.5x (achieved)
BF16 cos_min preservation	≥ 0.997	0.9977	≥ 0.997 (V1.0.1 baseline preserved) ✓

V1.3 QAT 启动准备

ADR-011 V1.3 QAT 4 条启动门槛： 1.  Data unblock (ImageNet val 50K via Kaggle workaround, 第 67 轮已达成) 2.  Training resource (A100/H100 GPU-day ≥ 5) 3.  Time budget (1-2 月专项工程 + 1 月 paper writing) 4.  Downstream baseline (depth/segmentation 任务 mAP 验证)

V1.0.2 的 PTQ precision wall 实证强化了 V1.3 QAT 的必要性 — 这是 paper §6 limitations + §7 future work 的关键素材。

V1.0.2 ship 包

- 4 ADRs Implemented (012/013/015/016)

- 综合 precision-wall 论证 (5 PTQ vector 全部失败 root cause 一致)
- 47 新测 + bit-exact 跨语言 parity
- V1.0.0 数字保留不退化

V1.0.2 是 V1.3 QAT 的必要前置 — 系统性证明了 PTQ 路径已穷尽, QAT 是唯一通路。

11. 一句话总结

V1.0.2 在 TRT 10.13.2.6 上系统性论证了 ViT-L/16 的 PTQ precision wall (BF16 是唯一例外, INT8/FP8/2:4-sparsity 全部失败), 实测 envelope 3.45x cpp r518 b8 (vs 5.0x 旗舰), 交付 4 ADRs Implemented + 47 新测 + comprehensive negative-result documentation 作为 V1.3 QAT 论证素材。

— END OF V1.0.2 DELTA REPORT —